

第3章 最佳逼近和最小二乘法

3.1 问题的提出

3.2 内积空间中的最佳逼近

3.3 函数的最佳平方逼近

3.4 勒让德多项式和切比雪夫多项式

3.5 曲线(数据)拟合的最小二乘法

3.6 $C[a,b]$ 中最佳一致逼近


3.5 曲线拟合的最小二乘法

在工程计算和统计分析中，常常遇到大量带有误差的实验数据，需要将这些数据拟合成一条函数曲线。从而总结、验证变量之间满足的函数关系，称这种问题为**曲线拟合**。它要求构造一个不必严格满足所有离散数据的近似函数（曲线），但使逼近的总体误差达到最小。根据**最佳平方逼近**准则（**2-范数度量误差**）进行的曲线拟合方法就称为**最小二乘法**。

例1 已知热敏电阻数据:

温度 $t(^{\circ}\text{C})$	20.5	32.7	51.0	73.0	95.7
电阻 $R(\Omega)$	765	826	873	942	1032

求 60°C 时的电阻 R 。



根据数据描绘散点图，数据点近似分布在一条直线上，故设拟合曲线为 $S = a + bt$ ， a, b 为待定系数

求出待定常数 a 和 b , 使得计算值 S_i 与实测值 R_i 之间的整体绝对误差最小.

比如 误差 $E_1 = \sum_{i=1}^5 |(a + bt_i) - R_i|$

误差 $E_2 = \sqrt{\sum_{i=1}^5 [(a + bt_i) - R_i]^2}$ 最小


用 E_2 度量方法求出拟合曲线 $S = a + bt$ 称为一次最小二乘拟合或一次最佳平方逼近.

例2 一种药物快速静脉注射下的血药浓度数据($t=0$ 注射300mg)

t (h)	0.25	0.5	1	1.5	2	3	4	6	8
c ($\mu\text{g/ml}$)	19.21	18.15	15.36	14.10	12.89	9.32	7.45	5.24	3.01

求血药浓度随时间的变化规律 $c(t)$.

作半对数坐标系 (semilogy) 下的图形



根据数据描绘散点图,
设拟合曲线为

$$c(t) = c_0 e^{-kt}$$

(c_0, k 为待定系数)

$$\Leftrightarrow s(t) = \ln c(t) = \ln c_0 - kt$$

即 $s(t) = a + bt$

问题的描述：已知离散数据表 $(x_i, f(x_i))_{i=1 \sim m}$ ，选取逼近表格

函数 $f(x)$ 的函数类 ϕ ，求拟合函数 $S^*(x) \in \phi$ ，使得

$$\left\| \{f(x_i) - S^*(x_i)\}_{i=1 \sim m} \right\| = \min_{S(x) \in \phi} \left\| \{f(x_i) - S(x_i)\}_{i=1 \sim m} \right\|$$

由于 $\delta = \{\delta_i\} \triangleq \{f(x_i) - S(x_i)\} \in R^m$,

$$\delta^* = \{\delta_i^*\} \triangleq \{f(x_i) - S^*(x_i)\} \in R^m,$$

问题即是在 m 维向量空间 R^m 中的最佳逼近问题.

取2-范数时，该方法称为**最小二乘法**(最佳平方逼近)；

取 ∞ -范数时，该方法称为**最佳一致逼近法**.

离散数据的最小二乘拟合

定义函数的离散加权内积

$$(f, g) = \sum_{i=1}^m \omega_i f(x_i) g(x_i)$$

其中 ω_i 为 $f(x)$ 在点 x_i 处的权, $\omega_i \geq 0$, $i = 1, 2, \dots, m$.

内积诱导的2-范数 $\|f\|_2 = \sqrt{\sum_{i=1}^m \omega_i f^2(x_i)}$

注: ω_i 可以表示在 $(x_i, f(x_i))$ 处重复观测的次数.

定义 设 $\{\varphi_1(x), \varphi_2(x), \dots, \varphi_n(x)\}$ 是 $C[a, b]$ 中的 n 个线性无关

的函数, 子空间 $M = \text{span} \{\varphi_1, \varphi_2, \dots, \varphi_n\}$, $S(x) = \sum_{i=1}^n \alpha_i \varphi_i(x) \in M$.

已知 $f(x) \in C[a, b]$ 在 m 个互异点 $x_i (i = 1 \sim m)$ 测试数据 $(x_i, f(x_i))_{i=1 \sim m}$,

求 $S^*(x) = \sum_{i=1}^n \alpha_i^* \varphi_i(x) \in M$,

$$\text{s. t.} \quad \sqrt{\sum_{i=1}^m \omega_i [f(x_i) - S^*(x_i)]^2} = \min_{S(x) \in M} \sqrt{\sum_{i=1}^m \omega_i [f(x_i) - S(x_i)]^2}$$

$$\text{即} \quad \sum_{i=1}^m \omega_i [f(x_i) - \sum_{j=1}^n \alpha_j^* \varphi_j(x_i)]^2 = \min_{\{\alpha_i\} \in K^m} \sum_{i=1}^m \omega_i [f(x_i) - \sum_{j=1}^n \alpha_j \varphi_j(x_i)]^2$$

称 $s^*(x)$ 为 $f(x)$ 在 M 中的**加权最小二乘拟合函数**,

求 $s^*(x)$ 的方法称为**最小二乘法**.

由法方程

$$\begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_2, \varphi_1) & \cdots & (\varphi_n, \varphi_1) \\ (\varphi_1, \varphi_2) & (\varphi_2, \varphi_2) & \cdots & (\varphi_n, \varphi_2) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_1, \varphi_n) & (\varphi_2, \varphi_n) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} (f, \varphi_1) \\ (f, \varphi_2) \\ \vdots \\ (f, \varphi_n) \end{bmatrix}$$

$$\text{求出 } (\alpha_1^*, \cdots, \alpha_j^*, \cdots, \alpha_n^*)^T \Rightarrow s^*(x) = \sum_{j=1}^n \alpha_j^* \varphi_j(x)$$

当 $f(x) \approx s^*(x)$ 时,

$$\begin{aligned} \text{均方误差 } \|\delta\|_2 &= \sqrt{\sum_{i=1}^m \omega(x_i) [f(x_i) - s^*(x_i)]^2} \\ &= \sqrt{(f, f) - \sum_{i=1}^n \alpha_i^* (f, \varphi_i)} \end{aligned}$$

例 3. 已知数据组

x_i	0.2	0.5	0.7	0.85	1
y_i	1.221	1.649	2.014	2.340	2.718

,
试用最小二乘法求 $f(x)$ 的二次拟合多项式 $P_2(x) = a_0 + a_1x + a_2x^2$.

解 权 $\omega_i = 1$, 取 $M = \text{span}\{1, x, x^2\} \triangleq \text{span}\{\varphi_0, \varphi_1, \varphi_2\}$, 计算

$$(\varphi_0, \varphi_0) = \sum_{i=1}^5 1 \times 1 = 5, \quad (\varphi_1, \varphi_0) = \sum_{i=1}^5 x_i \times 1 = 3.250,$$

$$(\varphi_2, \varphi_0) = \sum_{i=1}^5 x_i^2 \times 1 = 2.503, \quad (\varphi_1, \varphi_1) = \sum_{i=1}^5 x_i \times x_i = 2.503,$$

$$(\varphi_2, \varphi_1) = \sum_{i=1}^5 x_i^2 \times x_i = 2.090, \quad (\varphi_2, \varphi_2) = \sum_{i=1}^5 x_i^2 \times x_i^2 = 1.826,$$

$$(f, \varphi_0) = \sum_{i=1}^5 y_i \times 1 = 9.942, \quad (f, \varphi_1) = \sum_{i=1}^5 y_i \times x_i = 7.185,$$

$$(f, \varphi_2) = \sum_{i=1}^5 y_i \times x_i^2 = 5.857.$$

$$\text{法方程} \begin{bmatrix} 5 & 3.250 & 2.503 \\ 3.250 & 2.503 & 2.090 \\ 2.503 & 2.090 & 1.826 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 9.942 \\ 7.185 \\ 5.857 \end{bmatrix}.$$


求得 $a_0 = 1.036$, $a_1 = 0.751$, $a_2 = 0.928$.

故 $f(x) \approx P_2(x) = 1.036 + 0.751x + 0.928x^2$

$$\text{均方误差 } \|\delta\|_2 = \sqrt{\sum_{i=1}^5 [f(x_i) - s^*(x_i)]^2} \approx 0.0086$$


$$\text{均匀误差 } \|\delta\|_\infty = \max_{1 \leq i \leq 5} |f(x_i) - s^*(x_i)| \approx 0.0055$$

$$P_2(x) = 1.036 + 0.751x + 0.928x^2$$



例4 已知测得铜导线在温度 t_i 时的电阻 R_i ,求电阻 R 与温度 t 的关系.

i	1	2	3	4	5	6	7
T_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10



设各点的权 $\omega_i = \frac{1}{7} (i = 1 \sim 7)$

根据数据描绘散点图,
拟合曲线近似为

$$S = a + bt$$

i	1	2	3	4	5	6	7
t_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10

解 令 $\varphi_0=1$, $\varphi_1=t$, 权 $\omega_i=\frac{1}{7}$ ($i=1,2,\dots,7$)

$$(\varphi_0, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 1 \times 1 = 1, \quad (\varphi_1, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 t_i \times 1 = \frac{245.3}{7}, \quad (\varphi_1, \varphi_1) = \frac{1}{7} \sum_{i=1}^7 t_i \times t_i = \frac{9325.83}{7},$$

$$(R, \varphi_0) = \frac{1}{7} \sum_{i=1}^7 R_i = \frac{566.5}{7}, \quad (R, \varphi_1) = \frac{1}{7} \sum_{i=1}^7 R_i \times t_i = \frac{20029.445}{7}$$

$$\text{法方程} \begin{cases} 7a + 245.3b = 566.5 \\ 245.3a + 9325.83b = 20029.445 \end{cases} \Rightarrow R \approx 70.572 + 0.291t$$

问：若权 $\omega_i=1$ ($i=1,2,\dots,7$), 计算结果如何？

用最小二乘法解决**实际问题**的步骤:

- (1) 由实验数据表, 画出表格函数的粗略图形——散点图;
- (2) 根据离散点的图形, 选取合适的拟合函数类型 Φ ,
- (3) 用最佳逼近方法求出拟合函数 $\varphi(x) \in \Phi$;
- (4) 通过实验结果验证拟合曲线的吻合性.

例5 已知一组实验数据 (t_i, y_i) 如表，用适当的函数对它们进行拟合.

t_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46
$\tilde{y}_i = \ln y_i$	1.6292	1.7561	1.8764	2.0082	2.1353

解 根据数据点分布的散点图，选取拟合函数为指数函数.

设 $y \approx Ae^{bt} \Leftrightarrow \ln y \approx \ln A + bt$ ，记 $\tilde{y} = \ln y$, $a = \ln A$,

则只需求出拟合函数 $\tilde{y} = a + bt$.

应用最小二乘法，解相应的法方程，求得

$$a = 1.1225, \quad b = 0.5057 \Rightarrow A = e^a = 3.0725.$$

所求数据的拟合曲线为 $y \approx 3.0725e^{0.5057t}$

练习.

已知一组试验数据，其中 ρ_i 为各数据点出现的次数，
试用最小二乘法求这些数据的拟合曲线.

t_i	1	2	3	4	5
f_i	4	4.5	6	8	8.5
ρ_i	2	1	3	1	1

答案： 所求拟合曲线为 $S^*(t)=2.5648+1.2037 t$

数值分析作业 4:


此次作业使用 python 语言编写代码完成，计算了普通最小二乘和加权最小二乘并作图加以比较。

代码展示:

```
1. import numpy as np
2. import matplotlib.pyplot as plt
3. import matplotlib.font_manager as fm
4. myfont = fm.FontProperties(fname='C:/Windows/Fonts/msyh.ttc') ##解决图乱码
5. %matplotlib inline
6. from sympy import *
7.
```

结果展示:

画出表格函数的粗略图形:



普通最小二乘法求出的参数：

$a_{\text{noweight}}=2.45000000000000$

$b_{\text{noweight}}=1.25000000000000$

普通最小二乘法求出的拟合曲线为：

$s(t)=2.4500+1.2500*t$

加权最小二乘法求出的参数：


$a_{\text{weight}}=2.56481481481481$

$b_{\text{weight}}=1.20370370370370$

加权最小二乘法求出的拟合曲线为：

$s(t)=2.5648+1.2037*t$

数据点与两条拟合曲线对比图如下：



题解编号 (4). 题解步骤 已知一维试验数据, P_i 为各数据点出现的次数


题解编号及修正 试用最小二乘法求这些数据的拟合曲线

t_i 1 2 3 4 5

f_i 4 4.5 6 8 8.5

P_i 2 1 3 1 1

f



解: 根据数据对应散点图

拟合曲线为 $S = a + bt$

令 $\varphi_0 = 1, \varphi_1 = t$, 权为 P_i ($P_i = 1, 2, 3, 1, 1$)

则有 $(\varphi_0, \varphi_1) = P \sum_{i=1}^5 P_i = 8$

$(\varphi_0, \varphi_1) = P \sum_{i=1}^5 P_i t_i = 2 + 2 + 9 + 4 + 5 = 22$

题解编号及修正 $(\varphi_0, \varphi_1) = \sum_{i=1}^5 P_i t_i^2 = 2 + 4 + 27 + 16 + 25 = 74$

$(f, \varphi_0) = \sum_{i=1}^5 P_i f_i = 8 + 4.5 + 18 + 8 + 8.5 = 47$

$(f, \varphi_1) = \sum_{i=1}^5 P_i f_i t_i = 8 + 9 + 54 + 32 + 42.5 = 145.5$

这方程 $\begin{bmatrix} 8 & 22 \\ 22 & 74 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 47 \\ 145.5 \end{bmatrix}$ 解得 $\begin{cases} a_0 = 1.20370 \\ a_1 = 2.56481 \end{cases}$

故得所求拟合曲线为 $S = 2.56481 + 1.20370t$

4. 题解编号及修正

```
plt.figure(figsize=(10,7),dpi=40)
plt.subplot(1,2,1)
plt.scatter(t,t,f)
plt.title('散点图'),fontproperties='Times',fontsize=16
plt.subplot(1,2,2)
plt.plot(tsp,10spax(1,4,0.000001),color='blue',label='f=10spax(1,4,0.000001)')
plt.scatter(t,t,f)
plt.title('最小二乘拟合曲线'),fontproperties='Times',fontsize=16
plt.show()
```

散点图



最小二乘拟合曲线



4. 题解编号及修正

```
def fit(x,y):
    n=len(x)
    x0=[1]*n
    x1=x
    y0=[1]*n
    y1=y
    A=[x0,x1]
    B=[y0,y1]
    A=np.dot(A,A)
    B=np.dot(A,B)
    A_inv=np.linalg.pinv(A)
    X=A_inv.dot(B)
    return X
```

由观察可知, 拟合曲线近似为直线 (一次).

$$\text{设 } S^*(t) = \alpha_0^* + \alpha_1^* t. \quad \varphi_0 = 1, \quad \varphi_1 = t.$$

权重分别为: $\frac{1}{4}, \frac{1}{8}, \frac{3}{8}, \frac{1}{8}, \frac{1}{8}$

$$(\varphi_0, \varphi_0) = 1 \quad (\varphi_0, \varphi_1) = (\varphi_1, \varphi_0) = 2.75$$

$$(\varphi_1, \varphi_1) = 9.25. \quad (f, \varphi_0) = 5.875 \quad (f, \varphi_1) = 18.1875.$$

$$\therefore \begin{pmatrix} 1 & 2.75 \\ 2.75 & 9.25 \end{pmatrix} \begin{pmatrix} \alpha_0^* \\ \alpha_1^* \end{pmatrix} = \begin{pmatrix} 5.875 \\ 18.1875 \end{pmatrix}$$

$$\text{解, 得: } \begin{pmatrix} \alpha_0^* \\ \alpha_1^* \end{pmatrix} = \begin{pmatrix} 2.5648 \\ 1.2037 \end{pmatrix}$$

$$\therefore S^*(t) = 2.5648 + 1.2037t$$

拟合曲线类型的选择依据

- 专业知识和经验;
- 离散点图的分布形状及特点;
- 反复计算比较误差、修正类型;
- 现有的自动选择数学模型的程序.

法方程的病态问题

- 在最小二乘拟合中, 若取基函数为 $\varphi_j(x) = x^j (j = 0, 1, \dots, n)$.

当 n 较大时, 法方程组是病态的.

通常采用离散点的**正交多项式**可避免法方程出现病态.

- 实际计算中也常采用低次多项式分段拟合.

例如

若子空间 $M = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$ 中的基 φ_i 关于数据点

$(x_i, y_i) (i = 0, 1, 2, \dots, m)$ 加权 $\omega(x_i)$ 正交, 即

$$(\varphi_j, \varphi_k) = \sum_{i=0}^m \omega(x_i) \varphi_j(x_i) \varphi_k(x_i) = \begin{cases} 0, & j \neq k \\ A_k > 0, & j = k \end{cases}$$

则法方程的解

$$a_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} = \frac{\sum_{i=0}^m \omega(x_i) f(x_i) \varphi_k(x_i)}{\sum_{i=0}^m \omega(x_i) \varphi_k^2(x_i)} \quad (k = 0, 1, \dots, n)$$

均方误差 $\|\delta\|_2 = \|f - s^*\|_2 = \sqrt{\|f\|_2^2 - \sum_{k=0}^n A_k (a_k^*)^2}$

构造离散点的正交多项式方法

根据给定的节点 x_0, x_1, \dots, x_m 及权函数 $\omega(x) \geq 0$, 构造出带权 $\omega(x)$ 的正交多项式 $P_0(x), \dots, P_n(x)$ ($n \leq m$).

$$\begin{cases} P_0(x) = 1, \\ P_1(x) = (x - \alpha_1)P_0(x), \\ P_{k+1}(x) = (x - \alpha_{k+1})P_k(x) - \beta_k P_{k-1}(x) \quad (k = 1, 2, \dots, n-1). \end{cases} \quad (\text{由G.-S正交化方法得到})$$

$$\begin{cases} \alpha_{k+1} = \frac{\sum_{i=0}^m \omega(x_i) x_i P_k^2(x_i)}{\sum_{i=0}^m \omega(x_i) P_k^2(x_i)} = \frac{(xP_k, P_k)}{(P_k, P_k)}, \\ \beta_k = \frac{\sum_{i=0}^m \omega(x_i) P_k^2(x_i)}{\sum_{i=0}^m \omega(x_i) P_{k-1}^2(x_i)} = \frac{(P_k, P_k)}{(P_{k-1}, P_{k-1})} \end{cases} \quad (k = 0, 1, \dots, n-1)$$

若取 $M = \text{span}\{P_0, P_1, \dots, P_n\}$, 则 $f(x)$ 在 M 中最小二乘拟合函数为

$$s^*(x) = \sum_{k=0}^n \alpha_k^* P_k(x)$$

其中
$$\alpha_k^* = \frac{(f, P_k)}{(P_k, P_k)} = \frac{\sum_{i=0}^m \omega(x_i) f(x_i) P_k(x_i)}{\sum_{i=0}^m \omega(x_i) P_k^2(x_i)} .$$

此方法求最小二乘函数不用解方程组，计算简单、稳定.

2.6 $C[a,b]$ 中的最佳一致逼近

以2-范数作为度量误差的标准，研究了函数空间 $C[a,b]$ 中的最佳逼近及离散情况下的最小二乘法，由此得到的最佳逼近函数 $S^*(x)$ ，误差 $\|\delta\|_2$ 反应了 $f(x)$ 的平均误差，但可能出现在某些点上的误差大于平均误差的情况。

为了解决这类问题，考虑用 ∞ -范数作为度量误差的标准.

定义 设 $f(x) \in C[a, b]$, $M_n = \text{span}\{1, x, x^2, \dots, x^n\}$,

若存在多项式函数 $P_n^*(x) \in M_n$, 使得

$$\|f(x) - P_n^*(x)\|_\infty = \min_{P_n(x) \in M_n} \|f(x) - P_n(x)\|_\infty$$

$$\text{即 } \max_{x \in [a, b]} |f(x) - P_n^*(x)| = \min_{P_n(x) \in M_n} \max_{x \in [a, b]} |f(x) - P_n(x)|$$

则称 $P_n^*(x)$ 是 $f(x)$ 在 $[a, b]$ 上的最佳一致逼近多项式

或切比雪夫逼近多项式.

连续函数的一次最佳逼近多项式

设 $f(x) \in C^2[a, b]$, 且 $f''(x)$ 在 (a, b) 内不变号, $M_1 = \text{span}\{1, x\}$, 则 $f(x)$ 在 M_1 中的最佳一致逼近多项式 $P_1(x) = a_0 + a_1x$, 即是连续函数 $f(x)$ 的一次最佳一致逼近多项式.

记 $x_1 = a, x_3 = b, f'(x) - a_1 = 0$ 的解记作 x_2 . 解方程组

$$\begin{cases} a_0 + a_1a - f(a) = a_0 + a_1b - f(b) \\ a_0 + a_1a - f(a) = f(x_2) - (a_0 + a_1x_2) \end{cases}$$

$$\Rightarrow a_1 = \frac{f(b) - f(a)}{b - a} = f'(x_2) \quad \text{由微分中值定理得}$$

$$a_0 = \frac{1}{2}[f(a) + f(x_2)] - \frac{f(b) - f(a)}{b - a} \cdot \frac{a + x_2}{2}.$$

故 $f(x) \approx P_1(x) = a_0 + a_1x$, 均匀误差 $R(x) = \max_{x \in [a, b]} |f(x) - P_1(x)| \leq ?$

内容小结

内积空间中的最佳逼近

1. 在 $C[a, b]$ 中 $\begin{cases} M = \text{span}\{1, x, x^2, \dots, x^n\} \\ M = \text{span}\{\text{正交多项式}\} \end{cases}$ 勒让德多项式
切比雪夫多项式

最佳平方逼近

$$\|\delta\|_2^2 = \|f(x) - S^*(x)\|_2^2 = \min_{S(x) \in M} \int_a^b p(x) [f(x) - S(x)]^2 dx$$

2. 在 \mathbb{R}^m 中 $M = \text{span}\{x_1, x_2, \dots, x_n\}$

最小二乘法 $\|\delta\|_2^2 = \min_{S(x) \in M} \sum_{i=1}^n [f(x_i) - S(x_i)]^2$

3. 在 $C[a, b]$ 中, 最佳一致逼近

$$\|\delta\|_\infty = \|f(x) - P_n^*(x)\|_\infty = \min_{P_n(x) \in M_n} \|f(x) - P_n(x)\|_\infty$$

作业 **P85 习题3**

1, 2, 3, 5, 7, 8, 10, 11, 12, 13